实验三: 倒排索引实验报告

小组成员: MF20330007 陈明远 MF20330003 陈迪MG20330095 朱志威

● 设计思路:

本次实验通过输入小说文件来获取词频,其中 Map 部分的输入为 line,输出为((world, bookname),1),然后通过自己设计的 combiner 将临时文件整合在一起,形成((world, bookname), sum),由于 key 值也是一个键值对,所以要重写 partitioner 函数,使得里面的 hash 函数的 key 只对 world 起作用,接着通过 reduce 函数将相同词的 bookname 和 sum 整合在一起,计算出平均数,然后输入所有 bookname 和出现次数。代码如下:

● InvertedIndex 代码:

```
    import org.apache.hadoop.conf.Configuration;

2. import org.apache.hadoop.fs.Path;
3. import org.apache.hadoop.io.IntWritable;
4. import org.apache.hadoop.io.Text;
5. import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.Mapper;
7. import org.apache.hadoop.mapreduce.Reducer;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
9. import org.apache.hadoop.mapreduce.lib.input.FileSplit;
10. import org.apache.hadoop.mapreduce.lib.input.TextInputFormat;
11. import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
12. import org.apache.hadoop.mapreduce.lib.output.TextOutputFormat;
13. import org.apache.hadoop.mapreduce.lib.partition.HashPartitioner;
14. import org.apache.hadoop.util.GenericOptionsParser;
16. import java.io.IOException;
17. import java.util.ArrayList;
```

```
18. import java.util.List;
19. import java.util.StringTokenizer;
20.
21. public class InvertedIndex {
       public static class InvertedIndexMapper extends Mapper<Object, Text, Tex</pre>
   t, IntWritable> {//自定义自己的 mapper, 输入的 key 是小说文件,输出一个单词和词
23.
           @Override
24.
           protected void map(Object key, Text value, Context context)
25.
            throws IOException, InterruptedException {
26.
               FileSplit fileSplit = (FileSplit) context.getInputSplit();
27.
               String filename = fileSplit.getPath().getName(); //获取文件的名
               String line = value.toString().toLowerCase();
28.
               StringTokenizer itr = new StringTokenizer(line);
29.
30.
               while (itr.hasMoreTokens()) {
31.
                   Text word = new Text();
32.
                   String temp = itr.nextToken();
                   if (filename.indexOf(".txt.segmented") > 0) {//因为输出要去
33.
   掉.txt.segmented
                       word.set(temp+ "," + filename.substring(₀, filename.inde
34.
   x0f(".txt.segmented")));
35.
                       context.write(word, new IntWritable(1));
36.
                   } else {
37.
                       word.set(temp + "," + filename.substring(0, filename.ind
   exOf(".TXT.segmented")));
                       context.write(word, new IntWritable(1));//只有写入 contex
38.
   才会生效
39.
                   }
40.
41.
           }
42.
43.
       }
44.
45
       public static class SumCombiner extends Reducer<Text, IntWritable, Text,</pre>
    IntWritable> {//定义自己的 combiner
           private IntWritable result = new IntWritable();
46.
           @Override
47.
48.
           public void reduce(Text key, Iterable<IntWritable> values, Context c
   ontext)
49.
                   throws IOException, InterruptedException {
50.
               int sum = 0;
51.
               for (IntWritable val : values) {
52.
                   sum += val.get();
```

```
53.
               }
54.
               result.set(sum);
55.
               context.write(key, result);
56.
57.
       }
58.
59.
       public static class NewPartitioner extends HashPartitioner<Text, IntWrit
   able> {//定义自己的 partitioner, 重写哈希函数
           @Override
60.
           public int getPartition(Text key, IntWritable value, int numReduceTa
61.
   sks) {
               String term = new String();
62.
               term = key.toString().split(",")[0];//将哈希函数的 key 变为词,
63.
   key[0]为词
64.
               return super.getPartition(new Text(term), value, numReduceTasks)
65.
           }
66.
67.
68.
       public static class InvertedIndexReducer extends Reducer<Text, IntWritab</pre>
   le, Text, Text> {
69.
           private Text word1 = new Text();
70.
           private Text word2 = new Text();
           String bookname = new String();
71.
72.
           static Text CurrentItem = new Text(" ");
73.
           static List<String> postingList = new ArrayList<String>();
74.
75.
           @Override
76.
           public void reduce(Text key, Iterable<IntWritable> values, Context c
   ontext)
77.
                   throws IOException, InterruptedException {
               int sum = 0;
78.
79.
               word1.set(key.toString().split(",")[0]);
               bookname = key.toString().split(",")[1];
80.
81.
               for (IntWritable val : values) {
                   sum += val.get();
82.
               }//将不同的 map 中统计的词频加在一起
83.
               word2.set(bookname + ":" + sum);
84.
                if (!CurrentItem.equals(word1) && !CurrentItem.equals(" ")) {//
85.
   相同词出现在不同小说中要整合在一起。
86.
                   StringBuilder out = new StringBuilder();
87.
                   long count = 0;
88.
                    for (String p : postingList) {
89.
                        out.append(p);
```

```
90.
                       out.append(";");
91.
                       count += Long.parseLong(p.substring(p.indexOf(":") + 1))
   ;//将不同小说中词频数加载一起,目的是为了求平均值
92.
                   StringBuilder out1 = new StringBuilder(String.format("%.2f",
93.
    ((double) count / postingList.size()))).append("," + out);//求平均值
94.
                   if (count > 0) {
95.
                       context.write(word1, new Text(out1.substring(₀, out1.las
   tIndexOf(";")).toString()));
96.
97.
                   postingList = new ArrayList<String>();
98.
               }
99.
               CurrentItem = new Text(word1);
100.
                postingList.add(word2.toString());
101.
            }
102.
103.
            @Override
104.
            protected void cleanup(Context context) throws IOException, Interru
   ptedException {//处理最后一个词
                StringBuilder out = new StringBuilder();
105.
106.
                long count = 0;
107.
                 for (String p : postingList) {
108.
                    out.append(p);
109.
                    out.append(";");
110.
                    count += Long.parseLong(p.substring(p.indexOf(":") + 1));
111.
                }
112.
                StringBuilder out1 = new StringBuilder(String.format("%.2f", ((
   double) count / postingList.size()))).append("," + out);
113.
                if (count > 0) {
                    context.write(word1, new Text(out1.substring(0, out1.lastIn
114.
   dexOf(";")).toString()));
115.
                }
116.
117.
        }
118.
        public static void main(String[] args) throws Exception {
119.
            Configuration conf = new Configuration();
120.
121.
            String[] otherArgs = new GenericOptionsParser(conf, args).getRemain
   ingArgs();
            if (otherArgs.length != 2) {
122.
123.
                System.err.println("Usage: input output");
124.
                System.exit(2);
125.
            Job job = Job.getInstance(conf, "InvertedIndex");//建立任务
126.
```

```
127.
             job.setJarByClass(InvertedIndex.class);
128.
             job.setMapOutputKeyClass(Text.class);
             job.setMapOutputValueClass(IntWritable.class);
129.
130.
             job.setInputFormatClass(TextInputFormat.class);
131.
             job.setOutputFormatClass(TextOutputFormat.class);
             job.setMapperClass(InvertedIndexMapper.class);
132.
133.
             job.setCombinerClass(SumCombiner.class);
             job.setPartitionerClass(NewPartitioner.class);
134.
135.
             job.setReducerClass(InvertedIndexReducer.class);
136.
             job.setOutputKeyClass(Text.class);
137.
             job.setOutputValueClass(Text.class);
             FileInputFormat.addInputPath(job, new Path(otherArgs[0]));
138.
139.
             FileOutputFormat.setOutputPath(job, new Path(otherArgs[1]));
             System.exit(job.waitForCompletion(true) ? 0 : 1);
140.
141.
         }
142. }
```

最终输出的部分结果和"江湖"和"风雪"两个单词的词频如下:

● 部分结果:

File - /user/2021st06/output/part-r-00000

Page 55 of 26673 ► ► C

一个个 1.73,卧龙生02.春秋笔:1;卧龙生05.飞花逐月:1;卧龙生06.飞铃:1;卧龙生09.风雨燕归来:1;卧龙生10.黑白剑:1;卧龙生11.黑白双娇:1;卧龙生13.剑无痕:1;卧龙生14.剑仙列传:3;卧龙生16.金笔点龙记:3;卧龙生17.金凤剪:1;卧龙生18.金剑雕翎:2;卧龙生19.惊鸿一剑震江湖:1;卧龙生20.梦幻之刀:1;卧龙生21.妙绝天香:2;卧龙生26.情剑无刃:2;卧龙生28.神州豪侠:1;卧龙生29.双凤旗:2;卧龙生32.天鹤谱:2;卧龙生34.天龙甲:2;卧龙生36.天香飙:3;卧龙生40.无名箫:1;卧龙生41.无形剑:1;卧龙生43.血剑丹心:4;卧龙生44.烟锁江湖:3;卧龙生46.摇花放鹰传:2;卧龙生47.一代天骄:1;卧龙生49.幽灵四艳:1;卧龙生51.玉手点将录:1;卧龙生54.指剑为媒:2;古龙02.白玉雕龙:1;古龙04.边城刀声:1;古龙08.苍穹神剑:1;古龙19.大人物:1;古龙24.护花铃:1;古龙27.血鹦鹉:1;古龙29.剑毒梅香:1;古龙30.剑客行:1;古龙32.剑玄录:6;古龙43.陆小凤06凤舞九天:1;古龙44.陆小凤07剑神一笑:2;古龙46.那一剑的风情:1;古龙58.情人箭:1;李凉02.霸枪艳血:1;李凉03.百败小赢家:1;李凉04.本尊分身:1;李凉07.赌棍小狂侠:1;李凉10.滑头傻小子:1;李凉13;江湖急救站:3;李凉15.江湖一担皮:1;李凉20.狂侠南宫鹰:1;李凉21.六宝江湖行:1;李凉22.矛盾天师:3;李凉33.妙贼丁小勾:2;李凉25.魔手邪怪:2;李凉26.奇神扬小邪续集:8;李凉27.奇神杨小邪:6;李凉34.天下第一当:3;李凉36.小鬼大赢家:1;李凉37.小鱼吃大鱼:3;李凉38.笑笑江湖:2;李凉40.新蜀山剑侠传续:1;李凉41.杨小邪发威:4;梁羽生02.冰川天女传:2;梁羽生03.冰河洗剑录:2;梁羽生07.弹指惊雷:1;梁羽生11.广陵剑:2;梁羽生12.瀚海雄风:1;梁羽生17.江湖三女侠:2;梁羽生19.狂侠天娇魔女:1;梁羽生20.联剑风云录:1;梁羽生23.龙虎斗京华:1;梁羽生26.女帝奇英传:2;梁羽生30.散花女侠:1;梁羽生38.云海玉弓缘:2;金庸04天龙八部:1;金庸06白马啸西风:1;金庸07鹿鼎记:2;金庸08笑傲江湖:1;金庸09书剑恩仇录:1;金庸11侠客行:1

图 1:部分输出结果(1)

File - /user/2021st06/output/part-r-00000

Page 61 of 26673 **◄ ◆ ▶ ■ C**

:1;李凉17.惊神关小刀:2;李凉18.酒赌小浪子:4;李凉19.酒狂任小赌:1;梁羽生19.狂侠天娇魔女:1;梁羽生21.梁羽生传奇:1;梁羽生 38.云海玉弓缘:1;金庸03连城诀:1

一个时间 1.30,卧龙生04.地狱门:1;卧龙生06.飞铃:1;卧龙生16.金笔点龙记:1;卧龙生23.飘花令:1;卧龙生24.七绝剑:2;卧龙生41.无形剑:1;卧龙生43.血剑丹心:2;古龙08.苍穹神剑:1;古龙26.浣花洗剑录:1;古龙48.飘香剑雨:1;古龙63.武林外史:1;李凉03.百败小赢家:1;李凉11.会醉才会赢:1;李凉15.江湖一担皮:1;李凉17.惊神关小刀:2;李凉18.酒赌小浪子:4;李凉19.酒狂任小赌:1;梁羽生19.狂侠天娇魔女:1;梁羽生21.梁羽生传奇:1;金庸03连城诀:1

一个是 1.47,卧龙生01.镖旗:1;卧龙生03.翠袖玉环:1;卧龙生06.飞铃:1;卧龙生10.黑白剑:1;卧龙生16.金笔点龙记:1;卧龙生17.金凤剪:3;卧龙生23.飘花令:2;卧龙生24.七绝剑:1;卧龙生27.琼楼十二曲:1;卧龙生28.神州豪侠:3;卧龙生31.桃花血令:1;卧龙生34.天龙甲:2;卧龙生44.烟锁江湖:2;卧龙生46.摇花放鹰传:1;古龙32.剑玄录:1

一个月 12.12,卧龙生01.镖旗:9;卧龙生02.春秋笔:30;卧龙生03.翠袖玉环:14;卧龙生04.地狱门:11;卧龙生05.飞花逐月:6;卧龙生06.飞铃:38;卧龙生07.飞燕惊龙:7;卧龙生08.风尘侠隐:12;卧龙生09.风雨燕归来:4;卧龙生10.黑白剑:13;卧龙生11.黑白双娇:10;卧龙生12.剑气洞彻九重天:14;卧龙生13.剑无痕:25;卧龙生14.剑仙列传:1;卧龙生15.绛雪玄霜:5;卧龙生16.金笔点龙记:36;卧龙生17.金凤剪:18;卧龙生18.金剑雕翎:6;卧龙生19.惊鸿一剑震江湖:11;卧龙生20.梦幻之刀:10;卧龙生21.妙绝天香:16;卧龙生22.女捕头:10;卧龙生23.飘花令:11;卧龙生24.七垒剑:3;卧龙生25.吐剑训还情剑:4;卧龙生26.情剑无刃:3;卧龙生27.琼楼十二曲:6;

图 2:部分输出结果(2)

File - /user/2021st06/output1/part-r-00000

Page 1 of 2 ⋈ ✓ ▶ ⋈ C

图 3: "江湖"输出结果(1)

File - /user/2021st06/output1/part-r-00000

Page 2 of 2 ⋈ ◀ ▶ ⋈ 🥶

酒赌小浪子:17;李凉19.酒狂任小赌:167;李凉20.狂侠南宫鹰:15;李凉21.六宝江湖行:72;李凉22.矛盾天师:59;李凉23.妙贼丁小勾:16;李凉24.妙贼丁小勾续集:13;李凉25.魔手邪怪:6;李凉26.奇神扬小邪续集:98;李凉27.奇神杨小邪:102;李凉28.忍者龟:77;李凉29.神偷小千:17;李凉30.淘气世家:81;李凉31.天才混混:89;李凉32.天才混混外集:27;李凉33.天齐大帝:62;李凉34.天下第一当:52;李凉35.武林嘻游记:180;李凉36.小鬼大赢家:29;李凉37.小鱼吃大鱼:42;李凉38.笑笑江湖:69;李凉39.新蜀山剑侠传:20;李凉40.新蜀山剑侠传续:1;李凉41.杨小邪发威:34;梁羽生01.白发魔女传:63;梁羽生02.冰川天女传:65;梁羽生03.冰河洗剑录:65;梁羽生04.冰晚寒光剑:4;梁羽生05.草莽龙蛇传:143;梁羽生06.大唐游侠传:97;梁羽生07.弹指惊雷:77;梁羽生08.飞凤潜龙:4;梁羽生09.风雷震九洲:135;梁羽生10.风云雷电:139;梁羽生11.广陵剑:149;梁羽生12.瀚海雄风:69;梁羽生13.还剑奇情录:8;梁羽生14.幻剑灵旗:27;梁羽生15.慧剑心魔:102;梁羽生16.剑网尘丝:127;梁羽生17.江湖三女侠:252;梁羽生18.绝塞传烽录:40;梁羽生19.狂侠天娇魔女:180;梁羽生20.联剑风云录:126;梁羽生21.梁羽生传奇:74;梁羽生22.龙凤宝钗缘:109;梁羽生23.龙虎斗京华:182;梁羽生24.鸣镝风云录:134;梁羽生25.牧野流星:35;梁羽生26.女帝奇英传:49;梁羽生27.萍踪侠影录:40;梁羽生28.七剑下天山:77;梁羽生29.塞外奇侠传:2;梁羽生30.散花女侠:48;梁羽生31.随笔集:笔花六宪:15;梁羽生24.或当生34.武当一剑:94;梁羽生35.武林天骄:45;梁羽生36.侠骨丹心:103;梁羽生37.游剑江湖:275;梁羽生38.云海玉弓缘:81;金庸01飞狐外传:67;金庸02雪山飞狐:29;金庸03连城诀:35;金庸04天龙八部:126;金庸05射雕英雄传:57;金庸06白马啸西风:5;金庸07鹿鼎记:75;金庸08 突傲江湖:199;金庸09书剑恩仇录:64;金庸10神雕侠侣:81;金庸11侠客行:61;金庸12倚天屠龙记:145;金庸13碧血剑:65;金庸14驾至37375

Cancel

Download

File - /user/2021st06/output2/part-r-00000

Page 1 of 1 ⋈ ◀ ▶ ⋈ 🥲

风雪 4.53,卧龙生01.镖旗:3;卧龙生07.飞燕惊龙:16;卧龙生08.风尘侠隐:1;卧龙生09.风雨燕归来:1;卧龙生12.剑气洞彻九重 天:36;卧龙生15.绛雪玄霜:4;卧龙生18.金剑雕翎:9;卧龙生19.惊鸿一剑震江湖:2;卧龙生22.女捕头:4;卧龙生25.七绝剑II还情剑:2; 卧龙生27.琼楼十二曲:1;卧龙生31.桃花血令:2;卧龙生36.天香飙:2;卧龙生38.铁剑玉佩:7;卧龙生39.铁苗神剑:7;卧龙生42.新仙鹤神针:15;卧龙生47.一代天骄:3;卧龙生49.幽灵四艳:1;卧龙生52.袁紫烟:6;古龙07.残金缺玉:7;古龙13.楚留香05蝙蝠传奇:1;古龙14.楚留香06桃花传奇:1;古龙20.多情剑客无情剑:4;古龙23.孤星传:2;古龙24.护花铃:1;古龙25.欢乐英雄:3;古龙29.剑毒梅香:2; 古龙31.剑气书香:3;古龙42.陆小凤05幽灵山庄:1;古龙46.那一剑的风情:3;古龙47.怒剑狂花:2;古龙56.七种武器06离别钩:1;古龙61.失魂引:14;古龙63.武林外史:24;古龙64.湘妃剑:5;古龙67.英雄无泪:8;李凉01.暗器高手:1;李凉02.霸枪艳血:5;李凉03.百败小赢家:1;李凉04.本尊分身:6;李凉09.红顶记:1;李凉11.会醉才会赢:1;李凉14.江湖双响炮:4;李凉16.江湖一品郎:1;李凉19.酒狂任小赌:32;李凉31.天才混混:4;李凉34.天下第一当:1;李凉36.小鬼大赢家:1;李凉39.新蜀山剑侠传:1;李凉40.新蜀山剑侠传续:12;梁羽生01.白发魔女传:4;梁羽生02.冰川天女传:5;梁羽生03.冰河洗剑录:1;梁羽生07.弹指惊雷:1;梁羽生09.风雷震九洲:1;梁羽生10.风云雷电:3;梁羽生12.瀚海雄风:1;梁羽生14.幻剑灵旗:1;梁羽生20.联剑风云录:1;梁羽生21.梁羽生传奇:1;梁羽生22.龙凤宝钗缘:5;梁羽生25.牧野流星:5;梁羽生26.女帝奇英传:3;梁羽生27.萍踪侠影录:3;梁羽生30.散花女侠:1;梁羽生37.游剑江湖:1;金庸07鹿鼎记:1;金庸10神雕侠侣:2;金庸10个天尾龙记:1

Cancel

Download

图 5: "风雪"输出结果

- 输出结果路径: /user/2021st06
- WebUI 报告:

